

	Nombre lignes dans la table : ?	947043						
N° Col	Nom de la colonne	Description	Disponibilité de la variable <i>a priori</i>	Type informatique	Taux de NA	Gestion des NA	Distribution des valeurs	Remarques sur la colonne
		Que représente cette variable en quelques mots ?	Pouvez vous connaître ce champ en amont d'une prédiction ? Aurez vous accès à cette variable en environnement de production ?	int64, float etc... Si "object", détaillez.	en %	Quelle mode de (non) - gestion des NA favorisez vous ?	Pour les variables catégorielles comportant moins de 10 catégories, énumérez toutes les catégories. Pour les variables quantitatives, détaillez la distribution (statistiques descriptives de base)	champs libre à renseigner
1	Identifiant du compteur	ID numérique du compteur, composé de l'identifiant du site et d'un identifiant unique propre à chaque compteur	oui	str	3,50%	Nous favorisons la suppression de cette colonne, car l'identifiant ne peut pas être déduit des autres colonnes. De plus, nous pouvons utiliser la colonne 'Nom du compteur' comme identifiant, car celle-ci est unique et fournie pour chaque compteur.	Catégorielle - sup. à 10 catégories	97 valeurs (il manque l'identifiant pour 11 compteurs, au total il y en a 108)
2	Nom du compteur	L'adresse du site + le sens de la voie (ex : NE-SO)	oui	str	0,00%	-	Catégorielle - sup. à 10 catégories	108 valeurs / compteurs uniques, c'est la colonne qui permet d'identifier tous les compteurs de manière définitive (0 ligne vide)
3	Identifiant du site de comptage	ID numérique du site de comptage en 9 chiffres	oui	float	3,50%	A priori, les lignes vides concernent des sites qui sont déjà présents dans le dataset. Une fois la colonne 'Nom du site de comptage' remplie (voir ci-dessous), il est ainsi possible de retrouver l'identifiant du site à partir des autres lignes pour lesquelles l'identifiant est disponible.	Quantitative	Modifier type en str (valeurs nominales)
4	Nom du site de comptage	L'adresse du site	oui	str	3,50%	Peut être déduit de la colonne 'Nom du compteur' qui contient l'adresse du site	Catégorielle - sup. à 10 catégories	66 valeurs uniques (un site peut avoir plusieurs compteurs). Au total 66 sites différents (lignes vides prises en compte)
5	Comptage horaire	Nombre de passages de vélos par heure	oui	int	0,00%	-	Quantitative	
6	Date et heure de comptage	Date et heure de comptage	oui	str	0,00%	-	Catégorielle - sup. à 10 catégories	
7	Date d'installation du site de comptage	Date d'installation du site de comptage	oui	str	3,50%	Le taux de valeurs manquantes est identique à celui de la colonne 'Identifiant du site de comptage'. Il s'agit très probablement des mêmes lignes vides. On peut donc gérer les valeurs manquantes de la même manière que pour l'identifiant du site.	Catégorielle - sup. à 10 catégories	Comme les compteurs ont été installés à des dates différents, la somme des comptages par compteur ne fournit pas forcément un indice représentatif de la fréquence des vélos sur un site donné. Il vaut mieux comparer la moyenne par heure.
8	Lien vers photo du site de comptage	URL vers une photo du site de comptage	oui	str	4,54%	Suppression de la colonne : Les photos sont dépendantes des compteurs. Ainsi, les colonnes relatives aux informations sur les images sont corrélées entre elles et n'apportent pas de valeur ajoutée à l'apprentissage automatique.	Catégorielle - sup. à 10 catégories	68 valeurs uniques. La colonne est utile dans une application visuelle (streamlit), mais ne sera pas retenue dans l'entraînement du modèle prédictif.
9	Coordonnées géographiques	Coordonnées du site en format latitude, longitude	oui	str	3,50%	Le taux de valeurs manquantes est identique à celui de la colonne 'Identifiant du site de comptage'. Il s'agit très probablement des mêmes lignes vides. On peut donc gérer les valeurs manquantes de la même manière que pour l'identifiant du site.	Catégorielle - sup. à 10 catégories	69 valeurs uniques (certains sites ont deux sets de coordonnées : Pont National, Pont de la Concorde, Pont du Garigliano)
10	Identifiant technique compteur	Un autre identifiant pour chaque compteur. Or, deux compteurs sur le même site ont a priori le même identifiant technique.	oui	str	4,54%	Peut être déduit des autres lignes comme ci-dessus	Catégorielle - sup. à 10 catégories	68 valeurs uniques. Le nombre des "Identifiant technique compteur" est inférieur au nombre des "Identifiant du compteur". En effet, deux identifiants compteur peuvent se voir attribuer le même identifiant technique. C'est le cas où nous avons deux compteurs sur une voie bi-directionnelle (exemple : NO-SE, SE-NO).
11	ID Photos	Regroupement de plusieurs liens vers des images du site	oui	str	4,54%	Suppression de la colonne : Les photos sont dépendantes des compteurs. Ainsi, les colonnes relatives aux informations sur les images sont corrélées entre elles et n'apportent pas de valeur ajoutée à l'apprentissage automatique.	Catégorielle - sup. à 10 catégories	68 valeurs uniques. La colonne 'Lien vers photo du site de comptage' contient déjà la photo principale du site.

	Nombre lignes dans la table : ?	947043						
N° Col	Nom de la colonne	Description	Disponibilité de la variable <i>a priori</i>	Type informatique	Taux de NA	Gestion des NA	Distribution des valeurs	Remarques sur la colonne
12	test_lien_vers_photos_du_site_de_comptage_	A priori, c'est la même information que nous trouvons dans la colonne 'Lien vers photo du site de comptage'.	oui	str	4,54%	Suppression de la colonne : Les photos sont dépendantes des compteurs. Ainsi, les colonnes relatives aux informations sur les images sont corrélées entre elles et n'apportent pas de valeur ajoutée à l'apprentissage automatique.	Catégorielle - sup. à 10 catégories	68 valeurs uniques, identiques à la colonne 'Lien vers photo du site de comptage'
13	id_photo_1	Contient la valeur "https://" sur chaque ligne	oui	str	4,54%	Suppression de la colonne : Les photos sont dépendantes des compteurs. Ainsi, les colonnes relatives aux informations sur les images sont corrélées entre elles et n'apportent pas de valeur ajoutée à l'apprentissage automatique.	Valeur unique	Supprimer car identique pour toutes les lignes, info non pertinente pour l'analyse du trafic
14	url_sites	URL qui pourrait représenter un dossier d'images pour un site donné. Impossible de vérifier car liens invalides.	oui	str	3,50%	Suppression de la colonne : Les photos sont dépendantes des compteurs. Ainsi, les colonnes relatives aux informations sur les images sont corrélées entre elles et n'apportent pas de valeur ajoutée à l'apprentissage automatique.	Catégorielle - sup. à 10 catégories	69 valeurs uniques, pas d'utilité apparente (les liens ne fonctionnent pas)
15	type_dimage	Le format de l'image fournie	oui	str	4,54%	Suppression de la colonne : Les photos sont dépendantes des compteurs. Ainsi, les colonnes relatives aux informations sur les images sont corrélées entre elles et n'apportent pas de valeur ajoutée à l'apprentissage automatique.	Valeur unique	Supprimer car identique pour toutes les lignes, info non pertinente pour l'analyse du trafic
16	mois_annee_comptage	Année et mois du comptage. Informations déjà contenues dans la colonne 'Date et heure de comptage'	oui	str	0,00%	-	Catégorielle - sup. à 10 catégories	14 valeurs uniques (identique pour toutes les extractions comme on est sur les 13 derniers mois glissants)